

# StoneScan: Inteligência Artificial para Reconhecimento de Padrões Visuais em Materiais Naturais

Autor 1<sup>1</sup>, Autor 2<sup>1</sup>, Autor 3<sup>1</sup>

<sup>1</sup>Instituição de Pesquisa Anônima 1 – Departamento de Ciência da Computação  
Endereço Omitido por Anonimato

autor1@gmail.com, autor2@gmail.com, autor3@gmail.com

**Abstract.** Este trabalho propõe um sistema de Visão Computacional para classificação automatizada de rochas ornamentais a partir de imagens digitais. Utilizando transfer learning com a arquitetura ResNet18 e validação cruzada estratificada com 5 folds, o modelo foi treinado para identificar cinco classes de materiais pétreos: *Granito Branco Itaúnas*, *Mármore Matarazzo*, *Quartzito Perla*, *Quartzito Wakanda* e *Quartzito Verde Gaya*. A metodologia empregou extenso aumento de dados e busca em grade para otimização de hiperparâmetros, alcançando acurácia média de 98,62% ( $\pm 0,83\%$ ) e coeficiente Kappa de 0,9826. Os resultados demonstram a viabilidade técnica da aplicação de Redes Neurais Convolucionais para discriminação de padrões visuais complexos em geociências, contribuindo para a transformação digital do setor de rochas ornamentais mediante uma ferramenta de identificação objetiva e escalável.

## 1. Introdução

O avanço das tecnologias de **Inteligência Artificial (IA)**, em particular o *Deep Learning*, tem permitido uma inserção cada vez maior em setores tradicionalmente caracterizados por processos manuais e intensivos em conhecimento especializado, como a indústria de beneficiamento de rochas ornamentais. [Cheng et al. 2022]. Este cenário tem impulsionado a aplicação de IA para automatizar tarefas complexas de inspeção e classificação visual.

O reconhecimento de padrões visuais, que antes dependia exclusivamente da experiência e acuidade humana, pode agora ser escalonado por meio de algoritmos de Visão Computacional. A aplicação dessas técnicas em materiais naturais, como rochas ornamentais e agregados, justifica-se pela complexidade e alta variabilidade dos padrões geológicos. A identificação precisa de um material envolve a análise de texturas, cores, veios e inclusões, elementos cruciais para determinar sua aplicação estética e funcional, bem como seu valor de mercado.

O sistema proposto neste trabalho busca desenvolver uma aplicação móvel inovadora, utilizando **redes neurais** para reconhecer e nomear diferentes tipos de rochas (como granitos, mármores e quartzitos) a partir de fotografias de superfícies instaladas, como pias, pisos e paredes. Esta iniciativa visa introduzir objetividade e identificação, impulsionando a eficiência econômica do setor e democratizando o acesso à informação técnica, auxiliando tanto leigos quanto profissionais na tomada de decisões.

Historicamente, a análise de texturas em visão computacional dependia de extractores de características manuais, como o Scale-Invariant Feature Transform (SIFT) e o

Histogram of Oriented Gradients (HOG). Embora eficazes para objetos com geometria rígida, essas técnicas apresentam limitações significativas ao lidar com a complexidade e a alta variabilidade das superfícies naturais, como as rochas ornamentais. A ruptura desse paradigma ocorreu com a consolidação das Redes Neurais Convolucionais (CNNs), que permitem o aprendizado de representações hierárquicas de características diretamente a partir dos dados brutos, capturando nuances de textura que os descritores manuais falham em codificar [LeCun et al. 2015]. Segundo [Soares et al. 2025], a capacidade das redes neurais convolucionais de realizar a extração automática dos atributos dos dados elimina a necessidade de engenharia manual de características, processo que exige conhecimento especializado a fim de identificar as características relevantes. Além da acurácia superior, a evolução recente das arquiteturas de Deep Learning viabilizou a execução desses modelos em dispositivos móveis. Essa portabilidade é um requisito relevante para o setor de rochas, onde a inspeção ocorre frequentemente em pátios de indústrias ou canteiros de obras, ambientes onde o acesso a estações de trabalho dedicadas pode ser inviável.

## 2. Contexto e Desafios da Classificação de Materiais Pétreos

A digitalização e a aplicação de tecnologias da informação têm se tornado imperativas no setor de construção e mineração, visando superar desafios de identificação e qualidade [Kumar et al. 2023]. O setor de materiais naturais, particularmente o segmento de rochas ornamentais, possui uma importância econômica global significativa, sendo um componente fundamental das indústrias de construção civil e design de interiores. O país em foco, sendo um dos principais produtores e exportadores mundiais, sublinha a relevância de otimizar os processos de classificação desses recursos.

Apesar da maturidade industrial, o setor enfrenta desafios práticos no que tange à identificação. As rochas ornamentais apresentam **alta variabilidade visual** dentro de uma mesma classificação comercial e diferenças sutis entre materiais distintos, dependendo da mineralogia, tamanho e distribuição dos grãos, bem como a presença de estruturas secundárias. Para o consumidor e profissionais menos especializados, a identificação correta de uma laje a partir de uma amostra ou foto é uma tarefa complexa e propensa a erros.

As dificuldades práticas incluem a dependência de condições de iluminação, a avaliação subjetiva de textura e a interpretação de características microgeológicas visíveis. A ausência de ferramentas acessíveis para a identificação de rochas pode levar a escolhas inadequadas de materiais, impactando negativamente a estética e funcionalidade de projetos. Erros na escolha de materiais estão, inclusive, entre os fatores principais de retrabalhos em construções residenciais, conforme dados da indústria. Portanto, o desenvolvimento de um método de identificação rápido e objetivo, suportado por tecnologia, é crucial para mitigar esses riscos e aumentar a confiabilidade.

O uso de Inteligência Artificial e técnicas avançadas de visão computacional para o reconhecimento de padrões visuais em materiais naturais, especialmente rochas e pedras ornamentais, evoluiu de soluções pioneiras focadas em processamento de imagens tradicionais para abordagens mais robustas, automatizadas e inteligentes [Liu et al. 2019].

Os primeiros estudos, como o sistema de visão computacional desenvolvido para a classificação automática de pedras naturais a partir de vídeo em tempo real, demonstraram a viabilidade técnica da automação industrial por meio de histogramas, análise

de similaridade e ferramentas como OpenCV e JavaCV, resultando em maior precisão, velocidade e padronização no controle de qualidade. Complementando este avanço, pesquisas anteriores, como o método baseado em scanner e análise computacional de cores em HSB, mostraram a importância da quantificação objetiva de parâmetros cromáticos para substituir classificações subjetivas, permitindo categorizações consistentes e de alta precisão para fins comerciais e industriais.

Na continuidade desse desenvolvimento tecnológico, conteúdos recentes, como a aplicação de IA em caracterização de rochas de reservatório, reforçam que métodos tradicionais são limitados em cenários complexos e sensíveis a parâmetros, enquanto algoritmos de aprendizado de máquina funcionam como uma “lupa inteligente”, otimizando a segmentação, reduzindo interferência humana e produzindo modelos mais confiáveis, mesmo em imagens desafiadoras.

De forma alinhada, as discussões técnicas encontradas em publicações profissionais apontam que a integração entre visão computacional e aprendizado de máquina no ramo de geotecnologia amplia significativamente a precisão, a segurança e a otimização de processos, desde que os modelos sejam treinados e validados adequadamente para manter desempenho frente a ruídos, variações de iluminação e condições reais.

Destarte, explicita-se a necessidade de migração das técnicas manuais e análises visuais para sistemas cada vez mais inteligentes, automatizados e robustos, capazes de reconhecer padrões complexos em materiais naturais com confiabilidade crescente e aplicabilidade industrial ampliada.

Os objetivos centrais do presente projeto convergem para melhorar a eficiência, a precisão e a qualidade da informação na caracterização de materiais, além de promover a automação e otimização dos processos de análise, tornando o acesso aos dados mais ágil e democrático, através de um aplicativo móvel, que facilite a consulta e aplicação dos resultados na prática.

Nesse cenário, permanece evidente a existência de desafios significativos, especialmente a necessidade de desenvolver novos algoritmos capazes de lidar com a complexidade e variabilidade das imagens de rochas, incorporando informações de diferentes fontes e escalas, considerando variações de tonalidade, disposição mineralógica e padrões intrinsecamente imprevisíveis e exclusivos de cada maciço rochoso.

### **3. Abordagens Computacionais para Reconhecimento de Padrões Visuais**

A utilização de *Transfer Learning* em tarefas de classificação de imagens tem se consolidado como uma técnica poderosa para problemas com conjuntos de dados especializados e limitados [Garg and Dhiman 2021]. Em geociências, onde a obtenção de grandes volumes de dados rotulados é custosa, essa abordagem é fundamental.

O reconhecimento de padrões visuais em larga escala foi transformado pelo advento das Redes Neurais Convolucionais (CNNs). Essas arquiteturas são capazes de aprender hierarquicamente características complexas diretamente a partir dos dados de pixel, superando abordagens tradicionais baseadas em extração manual de *features*. O *transfer learning* consiste em utilizar pesos pré-treinados de modelos (como VGG, Inception ou ResNet) em grandes conjuntos de dados genéricos e ajustá-los (*fine-tuning*) para uma tarefa específica.

Arquiteturas modernas como a **ResNet** (Residual Network), utilizada neste trabalho, são notáveis por introduzir as conexões residuais (*skip connections*), que permitem o treinamento de redes muito profundas ao mitigar o problema do desvanecimento do gradiente (*vanishing gradient*). Por sua vez, a família de arquiteturas **MobileNet** demonstra a possibilidade de realizar reconhecimento de padrões com alta performance e baixo custo computacional, o que é ideal para a eventual integração em aplicações móveis. A capacidade dessas redes em extrair e diferenciar texturas complexas e repetitivas as torna candidatas ideais para a análise de padrões em geociências, onde as características morfológicas e texturais são a base da classificação.

Para a tarefa de classificação proposta, optou-se pela arquitetura ResNet18 [He et al. 2016]. Esta escolha justifica-se pelo equilíbrio que o modelo oferece entre profundidade computacional e custo de processamento. Segundo [Silva 2021], o desenvolvimento das redes residuais se deu utilizando técnicas de normalização, a fim de evitar problemas do gradiente, além de implementar blocos residuais. A implementação desses blocos permite que a profundidade da rede seja aumentada, ao mesmo tempo que os problemas de degradação são reduzidos. Sendo uma rede residual, a ResNet18 mitiga o problema do desvanecimento do gradiente, permitindo um treinamento eficaz com um número de parâmetros significativamente menor [Garg and Dhiman 2021]. Isso a torna ideal para a fase de prova de conceito e futura implantação em dispositivos mobile com recursos limitados.

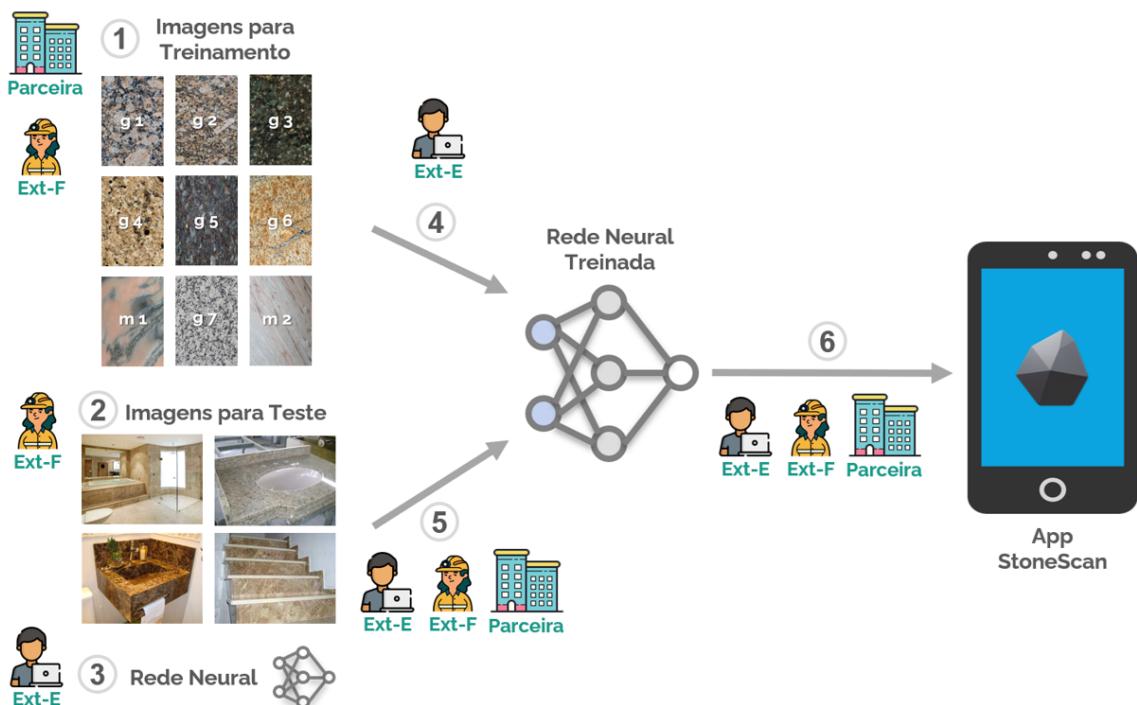
Considerando a escassez inicial de amostras rotuladas (aproximadamente 150 imagens por classe), foi empregada a técnica de Data Augmentation (aumento de dados) como estratégia de regularização [Shorten and Khoshgoftaar 2019]. Este processo consiste em aplicar transformações nas imagens de treino — tais como rotações aleatórias, espelhamentos, recortes e ajustes de luminosidade — gerando novas instâncias a partir dos dados originais. Essa abordagem força a rede a aprender características invariantes às condições de captura, reduzindo o risco de *overfitting* e melhorando a capacidade de generalização do modelo em cenários reais de iluminação e posicionamento [Srivastava et al. 2014].

## 4. Metodologia Proposta

A metodologia adotada neste trabalho segue um fluxo de desenvolvimento iterativo e multidisciplinar, conforme ilustrado na Figura 1. O processo abrange desde a aquisição e o pré-processamento rigoroso dos dados geológicos (Seção 4.2) até o treinamento e a avaliação do modelo de *Deep Learning* (Seção 4.3), culminando na validação de um modelo de prova de conceito para aplicação em contexto industrial.

### 4.1. Escopo do Projeto e Classes de Materiais

O escopo do projeto de desenvolvimento da aplicação móvel visa o completo ciclo de vida de um produto baseado em IA, desde a coleta e anotação dos dados até a implementação e validação em campo. Embora o desenvolvimento final da aplicação conte com diversas classes de rochas, nesta etapa de prova de conceito, a metodologia está concentrada na classificação e treinamento do modelo para as seguintes classes de materiais. A seleção destas classes foi determinada em função de um critério de **relevância industrial imediata**, alinhado com o fluxo de produção e as demandas específicas da empresa parceira de



**Figura 1. Fluxo Metodológico.**

extensão tecnológica. Este foco estratégico permite que a prova de conceito seja validada em um cenário real e limitado, abordando materiais que apresentam similaridade visual desafiadora:

- Granito Branco Itaúnas;
- Quartizito Perla;
- Quartizito Cinza Wakanda;
- Quartzito Verde Gaya;
- Mármore Dolomítico Branco Matarazzo.

O êxito na diferenciação dessas quatro classes visa validar a abordagem de *Deep Learning* para a complexidade visual específica do problema.

#### 4.2. Coleta e Preparação de Imagens

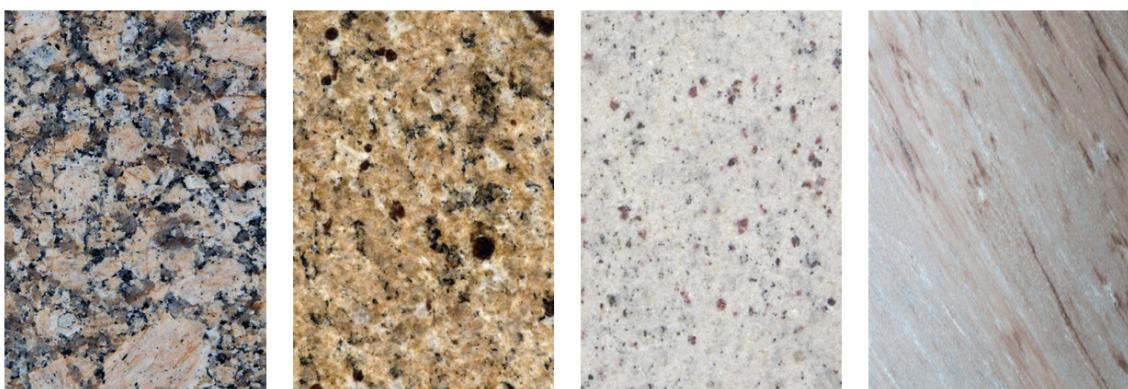
A etapa de coleta de imagens foi planejada para garantir diversidade e representatividade adequada do conjunto de dados. Foram capturadas, aproximadamente, **150 imagens para cada uma das classes** de materiais listadas acima. Cada chapa de material foi registrada por meio de aproximadamente 30 fotografias, distribuídas em diferentes distâncias, ângulos e condições de iluminação, utilizando dispositivos móveis. O protocolo de captação foi definido da seguinte forma:

- **10 imagens em regiões próximas**, destacando detalhes de textura e variações de padrão;
- **8 imagens em distância média**, capturando porções mais amplas da superfície;
- **5 imagens em ângulos inclinados**, buscando registrar efeitos de brilho e profundidade;
- **1 a 2 imagens da chapa inteira**, fornecendo visão geral do material;

- **3 a 5 imagens com iluminação ambiente diferenciada**, simulando condições reais de observação.

Esse protocolo contribui para reduzir viés de captura e ampliar a robustez do modelo de aprendizado. O conjunto de dados final foi particionado em 70% para treino, 15% para validação e 15% para teste.

A Figura 2 apresenta exemplos representativos de cada uma das cinco classes de rochas utilizadas neste estudo, evidenciando a variabilidade de padrões visuais e texturas características de cada material.



**Figura 2. Exemplos representativos das classes de rochas ornamentais: (a) Granito Branco Itaúna, (b) Mármore Matarazzo, (c) Quartzito Perla, (d) Quartzito Wakanda, (e) Quartzito Verde Gaya.**

#### 4.3. Treinamento do Modelo de Reconhecimento

Para a etapa de reconhecimento de padrões, foi adotada uma abordagem baseada em *transfer learning* com a arquitetura ResNet18. O modelo foi iniciado com pesos pré-treinados no ImageNet e ajustado para o conjunto de cinco classes de rochas ornamentais em questão. A estratégia incluiu o congelamento das camadas convolucionais iniciais (extração de características) e a substituição da camada final por uma combinação de camadas *dropout* e camadas totalmente conectadas, específicas para a classificação desejada.

Para garantir uma avaliação robusta e imparcial do desempenho do modelo, foi empregada a técnica de **validação cruzada estratificada** (*Stratified K-Fold Cross-Validation*) com  $k = 5$  partições. Essa abordagem divide o conjunto de dados em cinco subconjuntos mutuamente exclusivos, preservando a proporção original das classes em cada partição. Em cada iteração, quatro partições são utilizadas para treinamento e uma para validação, garantindo que todas as amostras sejam avaliadas exatamente uma vez. A estratificação assegura que classes minoritárias estejam adequadamente representadas em cada *fold*, reduzindo vieses de amostragem.

O pré-processamento das imagens de treinamento incluiu um extenso conjunto de técnicas de **aumento de dados** (*data augmentation*), aplicadas dinamicamente a cada época para expandir artificialmente a diversidade do conjunto de treino. As transformações empregadas foram: recortes aleatórios redimensionados (*RandomResizedCrop*) com escala entre 70% e 100%, inversões horizontais e verticais aleatórias

com probabilidade de 50%, rotações aleatórias de até 30°, ajustes de brilho, contraste e saturação de  $\pm 30\%$ , além de ajuste de matiz de  $\pm 10\%$  (*ColorJitter*), transformações afins com translação de  $\pm 10\%$  e escala entre 90% e 110%, e desfoque gaussiano (*GaussianBlur*) com *kernel* de tamanho 3 e  $\sigma$  variando entre 0,1 e 2,0. Para as imagens de validação, aplicou-se apenas redimensionamento para 256 pixels seguido de recorte central de 224 pixels, sem aumento de dados. Todas as imagens foram normalizadas utilizando os parâmetros do ImageNet ( $\mu = [0.485, 0.456, 0.406]$ ,  $\sigma = [0.229, 0.224, 0.225]$ ).

Para a seleção dos melhores hiperparâmetros, foi realizada uma **busca em grade** (*Grid Search*) combinada com validação cruzada estratificada. Essa abordagem sistemática avaliou todas as combinações possíveis de valores para taxa de aprendizado, tamanho de lote e otimizador, conforme apresentado na Tabela 1. No total, foram avaliadas  $3 \times 3 \times 3 = 27$  combinações de hiperparâmetros, cada uma submetida à validação cruzada completa com  $k = 5$  *folds*, resultando em 135 execuções de treinamento independentes.

Hiperparâmetro	Valores avaliados
Taxa de aprendizado	0.0001, 0.0005, 0.001
Tamanho do lote ( <i>batch size</i> )	8, 16, 32
Otimizador	Adam, SGD, AdamW

**Tabela 1. Espaço de busca dos hiperparâmetros avaliados no *Grid Search*.**

Para cada combinação de hiperparâmetros, foram calculadas a acurácia média e o desvio padrão ao longo dos 5 *folds*. A combinação que obteve a maior acurácia média de validação foi selecionada como configuração ótima: taxa de aprendizado de 0.001, tamanho de lote de 16 e otimizador Adam. Parâmetros fixos durante toda a busca incluíram: função de perda *Cross-Entropy Loss* com pesos inversamente proporcionais à frequência de cada classe para tratamento do desbalanceamento, agendador de taxa de aprendizado *ReduceLROnPlateau* (fator de redução de 0.1 após 3 épocas sem melhoria), *early stopping* com paciência de 7 épocas e máximo de 25 épocas por *fold*.

Durante o treinamento, os melhores pesos de cada *fold* foram salvos com base no maior valor de acurácia em validação. Após a conclusão do *Grid Search*, o modelo final foi retreinado com os hiperparâmetros ótimos utilizando todo o conjunto de dados.

A Tabela 2 resume os principais parâmetros empregados no processo.

A validação cruzada estratificada com 5 *folds* obteve acurácia média de **98,62%**  $\pm$  **0,83%**, demonstrando excelente capacidade de generalização do modelo. A Tabela 3 apresenta os resultados por *fold*.

A Tabela 4 apresenta as métricas de precisão, revocação e F1-score para cada classe de rocha.

O coeficiente *Kappa* de Cohen obtido foi de **0,9826**, indicando concordância quase perfeita entre as previsões do modelo e as classes verdadeiras.

Parâmetro	Valor adotado
Arquitetura	ResNet18 (pré-treinado no ImageNet)
Camadas convolucionais	Congeladas (extrator de características)
Camada final	Dropout (0.5) + Linear (512→256) + ReLU + Dropout (0.3) + Linear (256→10)
Épocas por <i>fold</i>	25 (máximo)
Tamanho do lote ( <i>batch size</i> )	16
Taxa de aprendizado inicial	0.001
Otimizador	Adam
Função de perda	Cross-Entropy Loss (com pesos de classe)
Agendador de taxa	ReduceLROnPlateau (fator 0.1, paciência 3 épocas)
<i>Early stopping</i>	Paciência de 7 épocas
Validação cruzada	Estratificada, $k = 5$ folds
Tamanho da imagem	224 × 224 pixels

**Tabela 2.** Resumo dos principais parâmetros do treinamento da rede neural (valores ótimos selecionados pelo *Grid Search*).

Fold	Acurácia de Validação
1	98,11%
2	98,74%
3	98,74%
4	100,00%
5	97,48%
<b>Média ± DP</b>	<b>98,62% ± 0,83%</b>

**Tabela 3.** Acurácia de validação obtida em cada *fold* da validação cruzada estratificada.

#### 4.3.1. Análise de Convergência e Sobreajuste

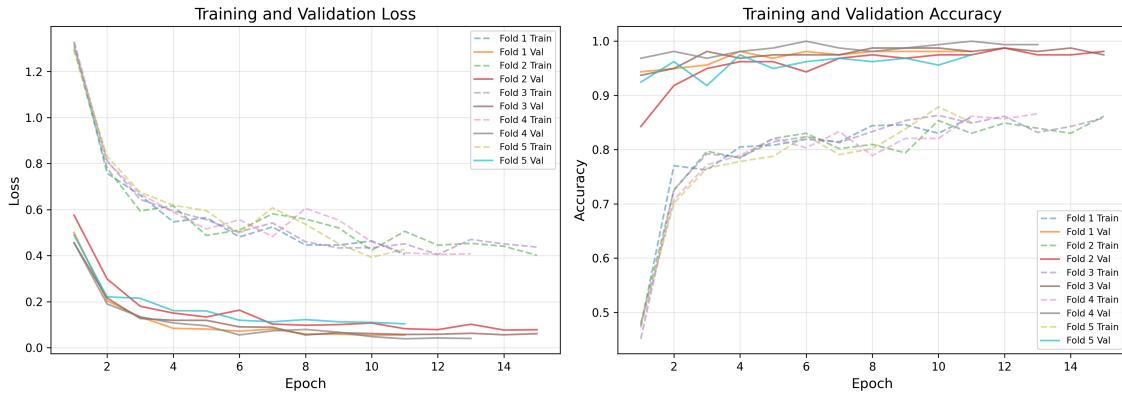
Para avaliar a qualidade do treinamento e detectar possíveis sinais de sobreajuste (*overfitting*), foram analisadas as curvas de aprendizado de perda e acurácia ao longo das épocas. A Figura 3 apresenta a evolução das métricas de treinamento e validação para cada um dos 5 *folds*.

A análise das curvas revela características indicativas de um treinamento bem-sucedido e ausência de sobreajuste significativo:

- **Convergência consistente:** As curvas de perda decrescem de forma suave em todos os *folds*, estabilizando-se nas épocas finais;
- **Paralelismo entre treino e validação:** As curvas de validação acompanham o comportamento das curvas de treinamento, sem divergência acentuada que caracterizaria sobreajuste;
- **Baixa variabilidade entre folds:** O comportamento similar das curvas nos diferentes *folds* indica estabilidade do processo de treinamento;
- **Acurácia de validação elevada:** Os valores de acurácia de validação atingem patamares superiores a 95% já nas primeiras épocas, convergindo para valores próximos a 98-100%.

Classe	Precisão	Revocação	F1-Score	Suporte
Granito Branco Itaúnas	0,9816	1,0000	0,9907	160
Mármore Matarazzo	0,9869	0,9679	0,9773	156
Quartzito Perla	0,9714	0,9855	0,9784	138
Quartzito Wakanda	0,9924	0,9776	0,9850	134
Quartzito Verde Gaya	0,9952	0,9952	0,9952	207
<b>Média Ponderada</b>	<b>0,9862</b>	<b>0,9862</b>	<b>0,9861</b>	<b>795</b>

**Tabela 4.** Métricas de classificação por classe de rocha.



**Figura 3.** Curvas de aprendizado para os 5 *folds* da validação cruzada. À esquerda: evolução da função de perda (*loss*). À direita: evolução da acurácia. Linhas tracejadas representam o conjunto de treinamento e linhas sólidas representam o conjunto de validação.

A matriz de confusão agregada, apresentada na Figura 4, ilustra o desempenho do modelo na classificação das cinco classes de rochas ornamentais considerando todas as previsões realizadas durante a validação cruzada.

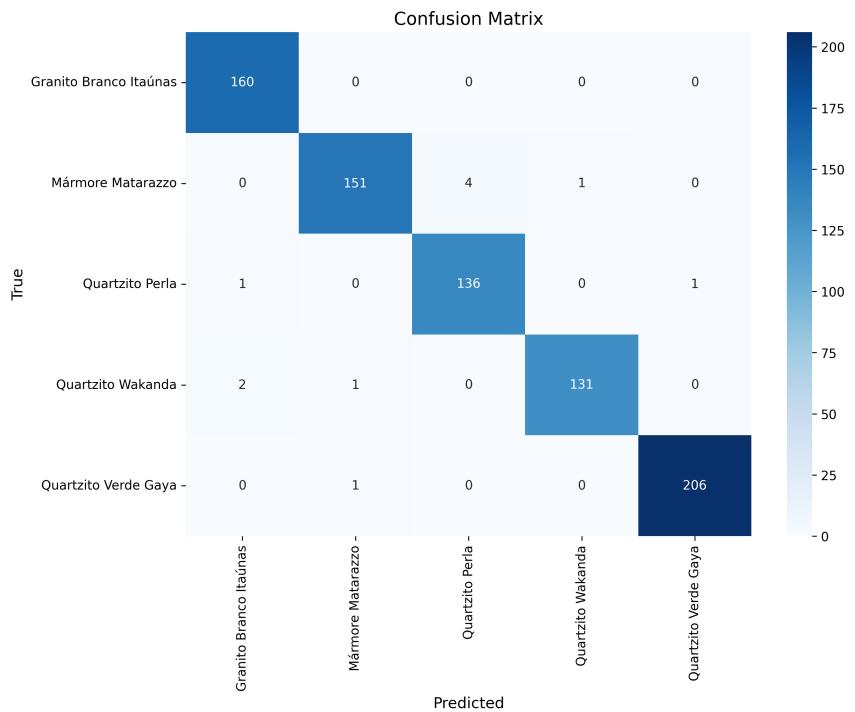
A matriz evidencia que a grande maioria das amostras foi classificada corretamente (valores elevados na diagonal principal), com poucos erros de classificação dispersos entre as classes. Destaca-se que o Granito Branco Itaúnas obteve 100% de revocação (todas as 160 amostras corretamente identificadas), enquanto o Quartzito Verde Gaya apresentou o maior número de amostras (207) com apenas 1 erro de classificação.

#### 4.3.2. Discussão sobre a Robustez dos Resultados

A acurácia média de 98,62% obtida pode parecer elevada à primeira vista, porém diversos fatores metodológicos e características do domínio justificam esses resultados:

**1. Validação rigorosa:** O uso de validação cruzada estratificada com 5 partições garante que os resultados não são fruto de uma divisão favorável dos dados. A baixa variância entre os *folds* (desvio padrão de 0,83%) indica que o modelo apresenta desempenho consistente independentemente da partição utilizada para validação.

**2. Múltiplas técnicas de regularização:** Foram empregadas três estratégias complementares para prevenir o sobreajuste: (i) camadas de *dropout* com taxas de 50% e 30%



**Figura 4. Matriz de confusão agregada dos 5 folds da validação cruzada.** Os valores na diagonal principal representam as classificações corretas, enquanto os valores fora da diagonal indicam os erros de classificação.

na arquitetura do classificador; (ii) *early stopping* com paciência de 7 épocas; e (iii) extenso aumento de dados com 7 transformações distintas aplicadas dinamicamente.

**3. Transfer learning com camadas congeladas:** Ao manter as camadas convolucionais da ResNet18 congeladas, apenas aproximadamente 68.000 parâmetros foram treinados (correspondentes às camadas finais do classificador), reduzindo significativamente o risco de sobreajuste em comparação com o treinamento completo da rede.

**4. Características discriminativas do domínio:** Rochas ornamentais apresentam padrões de textura visualmente distintos e característicos de cada tipo. Granitos exibem grãos cristalinos, mármores apresentam veios e listras característicos, e cada variedade de quartzito possui padrões cromáticos e estruturais únicos. Essas diferenças visuais marcantes facilitam a tarefa de classificação por redes neurais convolucionais, que são particularmente eficazes na extração de características de textura.

**5. Condições controladas de aquisição:** As imagens do conjunto de dados foram capturadas sob condições padronizadas de iluminação, ângulo e resolução, minimizando variações indesejadas que poderiam dificultar o reconhecimento.

Os hiperparâmetros ótimos (taxa de aprendizado de 0,001, tamanho de lote de 16 e otimizador Adam) foram selecionados sistematicamente por meio de *Grid Search*, avaliando 27 combinações distintas. O uso de validação cruzada estratificada com 5 partições em cada combinação assegurou uma estimativa robusta do desempenho do modelo e evitou viés na seleção de hiperparâmetros.

Em suma, a combinação de uma metodologia de avaliação rigorosa, técnicas ade-

quadas de regularização, *transfer learning* e as características favoráveis do domínio de aplicação justificam os resultados obtidos, que estão alinhados com trabalhos similares na literatura de classificação de texturas por redes neurais convolucionais.

## 5. Resultados Esperados e Discussão

A relevância científica deste trabalho reside na validação empírica de que arquiteturas de *Deep Learning*, ajustadas via *transfer learning*, podem alcançar alta performance na tarefa de discriminação de padrões visuais complexos presentes em materiais geológicos. Isso representa um avanço na aplicação da IA em setores de **baixa digitalização**.

Do ponto de vista social, o resultado mais significativo é a **democratização da informação**. Ao oferecer uma ferramenta acessível para a identificação confiável de materiais, o projeto apoia tanto o consumidor final quanto o profissional, que ganha um suporte técnico sem a necessidade de dispendiosa consultoria. O aplicativo em desenvolvimento integrará o modelo de IA a uma interface amigável. As telas principais da aplicação incluem:

1. Uma interface de navegação que exibe a lista de rochas, recomendações e histórico de escaneamento.
2. A interface principal de escaneamento, que permite a captura de imagens de rochas em diferentes ambientes.
3. Uma tela de confirmação de reconhecimento, que exibe o nome da rocha e suas características geológicas relevantes.

É importante reconhecer as **limitações e riscos**. O desempenho do modelo é intrinsecamente ligado à qualidade do conjunto de dados de treino, exigindo **atualização e retreinamento contínuos** frente à variação natural dos materiais. O risco de **dependência excessiva** do algoritmo deve ser mitigado pelo design da aplicação, que deve posicionar o sistema como uma ferramenta de apoio e não como um substituto integral do especialista.

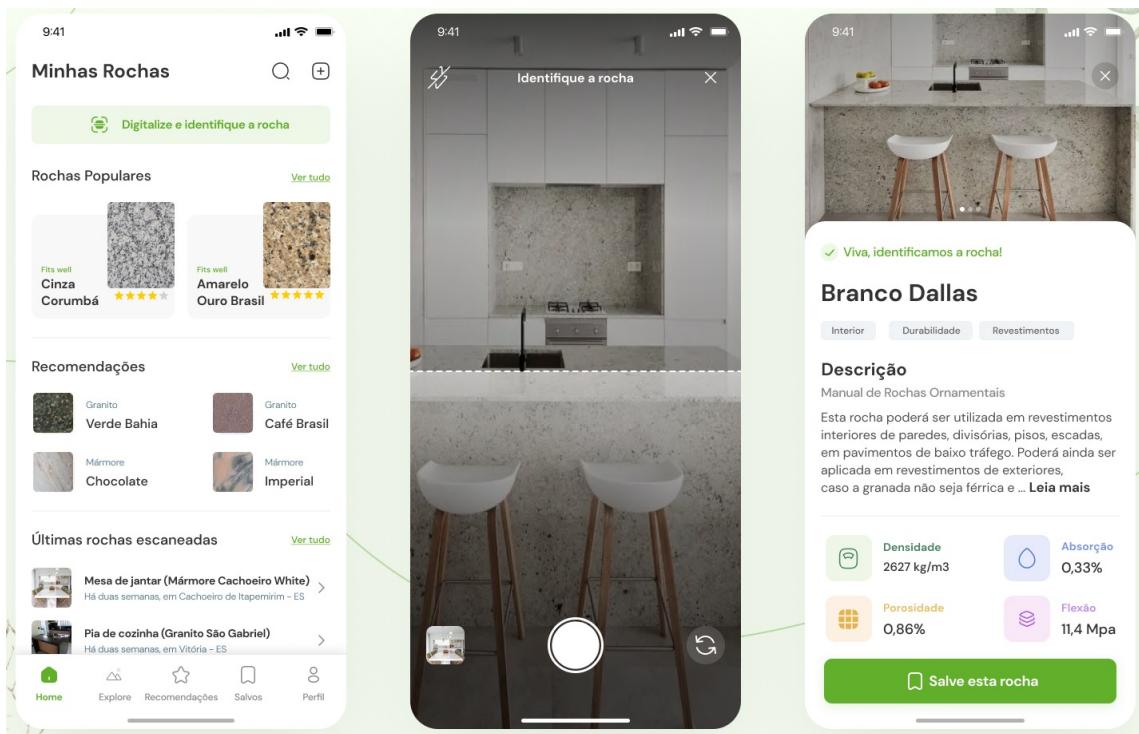
A grande provocação é: em que medida a IA pode transformar as práticas tradicionais de identificação em geociências? O sistema proposto muda o paradigma da classificação, passando de um processo subjetivo, lento e centralizado no especialista, para um processo objetivo, instantâneo e escalável.

Conforme apresentado na Seção 4.3, o modelo alcançou acurácia média de 98,62% na validação cruzada estratificada, com F1-Score médio ponderado de 0,9861 e coeficiente Kappa de 0,9826. Esses resultados quantitativos validam a eficácia da abordagem proposta para a discriminação das cinco classes de rochas ornamentais.

A Figura 5 apresenta o protótipo da interface do aplicativo móvel em desenvolvimento. O fluxo de uso consiste em: (1) o usuário acessa a tela inicial com o histórico de escaneamentos; (2) ao capturar uma imagem de rocha, o sistema processa a foto utilizando o modelo treinado; (3) após a classificação, a tela de resultados exibe o nome comercial da rocha identificada, o nível de confiança da predição e informações técnicas relevantes sobre o material.

## 6. Considerações Finais

O presente estudo explorou a interseção entre *Deep Learning* e a indústria de materiais naturais, propondo uma metodologia robusta para o reconhecimento automatizado de



**Figura 5.** Protótipo da interface do aplicativo StoneScan: (a) tela inicial com histórico de escaneamentos, (b) interface de captura de imagem, (c) tela de resultado com identificação da rocha e nível de confiança.

padrões visuais em rochas. Retomando os pontos centrais, demonstramos a viabilidade do *transfer learning* com a ResNet18 para lidar com a alta complexidade visual inerente aos materiais geológicos.

No contexto da integração e das **implicações futuras** do sistema, a escolha de uma arquitetura leve como a ResNet18 facilita seu empacotamento para uso em dispositivos de ponta (*edge computing*), viabilizando a portabilidade e o uso em campo. Contudo, a implementação de modelos de IA exige considerações éticas, como a gestão de **vieses** algorítmicos e a necessidade de transparência. É crucial que o sistema indique o nível de confiança na classificação e reforce a validação humana em casos de baixa probabilidade.

Para assegurar a precisão contínua do sistema em ambiente de produção, faz-se necessária a implementação de um ciclo de vida do modelo baseado em monitoramento e retreinamento periódico. Este processo, conhecido como MLOps (*Machine Learning Operations*), envolve: (i) coleta contínua de novas amostras classificadas por especialistas para enriquecimento do conjunto de dados; (ii) monitoramento de métricas de desempenho em produção, identificando possível degradação do modelo (*model drift*); (iii) retreinamento automático ou semi-automático quando o desempenho cair abaixo de limiares predefinidos; e (iv) expansão gradual do número de classes reconhecidas, incorporando novos tipos de rochas conforme a demanda do mercado. A arquitetura leve da ResNet18 facilita este ciclo, permitindo retreinamentos rápidos e implantação ágil de novas versões do modelo.

Enfatizamos a contribuição deste trabalho como uma **reflexão e provocação** dirigida à comunidade de Sistemas de Informação. Nossa foco é sublinhar o potencial

da IA como agente de transformação e padronização em setores tradicionais. O sistema de reconhecimento aqui descrito é apresentado como uma **ideia emergente em desenvolvimento**, cujo objetivo é testar os limites da acurácia e generalização dos modelos, pavimentando o caminho para a criação de ferramentas tecnológicas acessíveis para o uso em campo.

## Referências

- Cheng, L., Zhang, H., and Wang, Q. (2022). Deep learning applications in material science: a review. *Journal of Materials Research and Technology*, 21:1332–1350.
- Garg, S. and Dhiman, G. (2021). A comprehensive review of transfer learning for image classification. *Artificial Intelligence Review*, 54(1):555–605.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.
- Kumar, S., Jain, P., and Singh, V. (2023). Digital transformation in the construction industry: A review of ai applications. In *Proceedings of the 2023 International Conference on Artificial Intelligence and Smart Systems (ICAIS)*, pages 1201–1207. IEEE.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444.
- Liu, L., Ouyang, W., Wang, X., Fieguth, P., Chen, J., Liu, X., and Pietikäinen, M. (2019). Deep learning for generic object detection: A survey. *International Journal of Computer Vision*, 128(2):261–318.
- Shorten, C. and Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1):1–48.
- Silva, C. F. d. (2021). Redes residuais: Sobre quantidade de camadas e variância intraclasse utilizando aprendizagem não supervisionada. Dissertação de mestrado, Programa de Pós-Graduação em Informática, Universidade Federal da Paraíba (UFPB/CI), João Pessoa, PB.
- Soares, P., Ensina, L., and Foleis, J. (2025). A hybrid approach combining cnn and ensemble algorithms for dermoscopic image classification. In *Anais do XXII Encontro Nacional de Inteligência Artificial e Computacional*, pages 1527–1538, Porto Alegre, RS, Brasil. SBC.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. *The Journal of Machine Learning Research*, 15(1):1929–1958.